## Compte rendu

de Antoine Malaval


L'objectif du projet est de créer un pipeline streaming dans le but de créer des graphes pour afficher les données recueillies.

Pour se faire, nous avons utilisé 4 technologies :

- Kafka
- Spark
- une base de données MySQL
- Apache superset

Plus techniquement, le projet a pour objectif de recueillir des données via l'API de Twitter, et de les envoyer sur le topic kafka que l'on crée. Par la suite un consumer spark se connecte à kafka afin de traiter les données reçues, les mettre en forme et les insérer dans la base de données MySQL. Pour finir, Apache Superset visualise les données en se connectant à notre base MySQL pour afficher les graphiques.

## résumé de l'utilisation des différents outils :



Dans un premier temps, nous devons installer des machines virtuelles grâce à Vagrant sur VirtualBox :

- une machine virtuelle pour python (script pour produire la donnée de l'API)
- une machine virtuelle pour Kafka
- une machine virtuelle pour Spark
- une machine virtuelle pour la base de données MySQL et Apache Superset

Une fois les machines créées nous nous sommes connecté aux machines en utilisant vagrant ssh.

Sur la machine Kafka, nous avons créé le topic qui nous servira à connecter le *producer* et le *consumer* puis envoyer des données de test.

J'ai choisi de me focaliser sur le nombre de followers des utilisateurs et les hashtags.

```
🕏 producer-streaming-twitter.py 🗶
C: > Users > antoi > OneDrive > Documents > esi5e-pipeline-streaming-twitter > 🌵 producer-streaming-twitter.py
       producer = KafkaProducer(bootstrap servers='192.168.33.13:9092')
      class Listener(Stream):
           tweetsProceeded = []
           limit = 100
           def on_data(self, raw_data):
               self.process_data(raw_data)
               return True
           def process_data(self, raw_data):
               if len(self.tweetsProceeded) == self.limit:
                   print("disconnecting...")
                   self.disconnect()
               else:
                   message = json.loads(raw_data)
                   if message['user']['location'] is not None:
                       print(message)
                       producer.send('tweets', raw_data)
                       self.tweetsProceeded.append(raw_data)
           def on_error(self, status_code):
               print(status code)
               if status code == 420:
                   # returning false in on_data disconnects the stream
                   return False
      # start the stream
       if __name__ == "__main__":
           auth = tweepy.OAuthHandler(API_KEY, API_KEY_SECRET)
           auth.set_access_token(ACCESS_TOKEN, ACCESS_TOKEN_SECRET)
           api = tweepy.API(auth)
           listener = Listener(API_KEY, API_KEY_SECRET,
                                ACCESS TOKEN, ACCESS TOKEN SECRET)
           keywords = ["*"]
           listener.filter(track=keywords)
```

Comme on peut le voir en lançant le script ci-dessus, les tweets sont affiché sur la console

```
(created pt: 'New May 84 160512) - 4888 222; 'Lai' 15328852828261627884, 'id_str': '152188528361627884', 'test': 'giusane_Seith From the first testement e', 'display_test_range': 135, 481, 'source': 'as href"http://twitter.com/dewnload/ighore' rel="horistors for iPhones/es", 'trancated': False, 'is_reply_te_pate_isis': 123883831206, 'is_reply_te_pate_isis_is': 123883831206, 'is_reply_te_pate_isis_is': 123883831206, 'is_reply_te_pate_isis_is': '1238838314888837318', 'is_reply_te_pate_isis_is': '123883831206, 'is_reply_te_pate_isis_is': '1238838314888837318', 'is_reply_te_pate_isis_is': '1238838314888837318', 'is_reply_te_pate_isis_is': '1238838318, 'is_reply_te_pate_isis_is': '12388318, 'is_reply_te_pate_is
```

une fois que le nombre de message à été produit, le stream se stop :

En lançant un kafka-console-consumer nous voyons bien les tweets passer également :

```
Wegnetite/Nation 1.7% [Assistance of the part of
```

Puis nous avons créé le job Spark qui va consommer les données du topic :

```
import string
       from pyspark.sql import SparkSession, Now
from pyspark.streaming import StreamingContext
from pyspark.streaming.kafka import KafkaUtils
       from pyspark.sql.types import FloatType, StringType
from pyspark.sql.functions import to_date
       import joon
 16
17
18
19
                   u"\008002422~\008019251"
u"\00801926~\00801937"
u"\u280d"
u"\u280d"
u"\u2640~\u2642"
u"\u2600~\u2855"
  21
22
23
24
                    u"\u23ef"
                   u"\u23e9"
u"\u231a"
 25
26
27
                   u"\u3030"
u"\ufe0f"
                                                      "]+", flags=re.UNICODE)
 29 def getHashtags[rdd_collected]:
30 list_hashtags = []
31 for element in rdd_collected:
               print(element)
  32
                     print(element;
for hashtag in element;
   if hashtag["text"] != Nuce;
        list_hashtags.append(hashtag["text"])
  33
34
  35
           return list_hashtags
38 def stripTextAndtemoveEmoji(text):

39 stringHithoutEmoji = emoji pattern.sub(r'', text)

40 nameIsBlank = re.mearch(''\m*5', stringWithoutEmoji)

41 if not stringHithoutEmoji or nameIsBlank :
42
             return stringWithoutEmoji.strip()
44
45
46
      def process(time, rdd):
                                                        " | str(time))
             print("

if not rdd.isEmpty():
    print(rdd)
49
50
51
                    locationDF = rdd.map(lambda tweet: Row(username-strigTextAndRemoveEmoji(tweet['user']['name']),
52
53
                                                           nb_friends=tweet['user']['friends_count'])).toDF()
                  54
55
56
53
                   locationDf.printSchema()
58
59
                  locationDF.write.format('jdbc').options(
   url='jdbc:mysql://192.168.33.10/data',
   dbtable='users',
60
61
62
                           password='admin').mode('append').save()
65
66
67
                  rdd_collected = rdd.map(lambda tweet: tweet("estities")["hashtags")).collect()
                  if len(rdd_collected) >= 1:
    hashtags list = getHashtags(rdd_collected)
    rdd_hashtags = sc.parallelios(hashtags_list)
if rdd_hashtags :sEmpty() == False:
    hashtagsDF = rdd_hashtags.map(lashda hashtagg: Row(hashtag-hashtagy)).toDF()
    hashtagsDF = rdd_hashtagsF.withColumn("hashtag", hashtagsDF("hashtag"].cast(StringType()))
    hashtagsDF.printSebema()
    hashtagsDF.withc.format('jdbc').options("hashtagsDF("hashtag")).toDF())
68
 69
70
 71
72
73
74
75
76
77
78
                                   hashtagit0.write.format(')doc').options(
url=')dbc:mysql://192.168.33.10/deta',
dbtable='hashtago',
user='admin',
password='admin').mode('append').save()
82 spark = SparkSession.builder \
83 .master("local[2]") \
            .master("local[2]")
.appName("data") \
.getOrCreate()
84
85
86
70 sc = spark.sparkContext
71 sc.setLogLevel("ERSOR")
72 ssc = StreamingContext(sc, 10)
74 directEafkaStream = KafkaUtils.createDirectStream(ssc, ["tweets"], ("metadata.broker.list": "192.168.33.13:9892"))
75 rdd = directEafkaStream.map(lambda tweet: json.loads(tweet(1)))
76 rdd.foreachRDD(process)
79 msc.start()
80 sec.eveitTermination()
```


Après avoir installé le wget spark-streaming-kafka et le déplacer dans le bon répertoire (à savoir les jars de spark), nous récupérons les données sur le consumer spark avec la commande spark-submit :

vagrant@vagrant:~\$ /usr/local/spark/bin/spark-submit spark-consumer-tweets.py

Pour vérifier que les données s'insèrent bien dans la base MySQL, je me suis connecté à MySQL et fait un Select pour les Users et les Hashtags.

select * from users;	select * from hashtags;
1083 rows in set (0.01 sec)	401 rows in set (0.00 sec)


Pour reprendre mon précédent schéma, en vert ce que nous avons fait, en rouge ce qu'il nous reste à faire :




Nous devons donc connecter notre base de données sur Apache Superset afin d'effectuer des actions sur les données :



Nous "convertissons" la base de données en dataset :



J'ai ainsi créé un Chart en fonction du nombre des hashtag présents dans la base de données grâce au count() :



Pour finir, j'ai créé un autre graph pour afficher les utilisateurs ayant le plus d'amis sur les données récupérer :

## - Users and friends Show 200 ✓ entries nb\_friends : username : 18553 allie. 9380 #TodosSomosUcrania #LaResistencia 7353 No name 6567 Fantasy \* Fragment of Time \* 6038 No name 5828 mikel ayestaran 5809 mika PROOF 0610 5375 duda de la roitTHOR 5000 Michael Van Vaerenbergh 4977 @ 4956 Abdulkareem 4947 Rain 4931 2015,10,18, 4910 may 4613 Mark W. Yusko #TwoPointOneQuadrillion 3702 @benedito\_xr#RGSDV #MFSDV 3702 @benedito\_xr#RGSDV #MFSDV